Guía de trabajo para fusionar *ws-dmaa* con *Appl. Sci.*

1 Guía de trabajo para fusionar *ws-dmaa* con *Appl. Sci.*

1.1 1. Punto de partida: qué quiero tomar de cada artículo y por qué

La idea de fondo es bastante simple, aunque metodológicamente tenga varias capas. Del artículo **ws-dmaa** quiero conservar el corazón del pipeline: a partir de interacciones usuario–ítem, inferir una red social implícita entre usuarios con **NETINF**, extraer propiedades de esa red y usar esas propiedades como atributos dentro de un esquema de **Collective Matrix Factorization (CMF)** para mejorar la predicción de ratings. Ese artículo trabaja con MovieLens, trata cada película como una cascada y luego agrega al modelo atributos de red como degree, betweenness, closeness, eigenvector, farness, community structure, eccentricity y hubs/authorities. Además, reporta que esta estrategia mejora frente al baseline de filtrado colaborativo clásico, y que el modelo exponencial de transmisión fue el que tuvo mejor comportamiento global.

Del artículo de **Appl. Sci.** quiero tomar una idea distinta, pero muy complementaria: no basta con saber qué usuarios están "bien conectados"; también importa detectar cuáles están situados en las **fronteras entre comunidades superpuestas**. Ahí entra la métrica $\tilde{h}_v$, que no busca hubs estructurales clásicos, sino nodos cuya membresía comunitaria está desalineada con la de su vecindario. El paper insiste en que $\tilde{h}_v$ es ortogonal a medidas puramente topológicas como BridgeCC, es interpretable, y resulta especialmente útil cuando las comunidades capturan grupos semántica o conductualmente coherentes.

Entonces, en una frase, la fusión que propongo es esta:

mantener la lógica predictiva de ws-dmaa, pero enriquecer la capa de atributos de usuario con una señal nueva de interfaz comunitaria, derivada de $\tilde{h}_v$, para que el recomendador no solo vea usuarios centrales, sino también usuarios frontera.

1.2 2. La intuición conceptual de la fusión

Yo no vendería esta fusión como "sumemos dos técnicas porque sí". La vendería más bien así: en recomendación, una parte de la señal viene de la **proximidad** y otra parte viene del **cruce entre grupos**.

ws-dmaa ya explota la primera bastante bien. Cuando uno infiere una red de usuarios desde sus secuencias temporales de rating, y luego usa propiedades de esa red como atributos del modelo, está capturando una idea razonable: hay usuarios que, aunque no estén explícitamente conectados en la plataforma, se comportan como si hubiera una estructura relacional subyacente entre ellos.

Pero ahí todavía falta algo: esa red inferida puede tener zonas muy densas, comunidades, interfaces, regiones de traslape. Y no todos los usuarios ubicados en esas zonas cumplen el mismo papel. Algunos son muy representativos de su comunidad; otros están justo en el borde, conectando perfiles, gustos o trayectorias que no son iguales. Ahí es donde Appl. Sci. aporta algo que, para mí, encaja casi de forma natural: **detectar nodos de frontera basados en desalineación de membresías**.

En términos más humanos: si ws-dmaa me ayuda a saber **quién se parece a quién** dentro de una red implícita, Appl. Sci. me ayuda a saber **quién conecta mundos distintos** dentro de esa misma red.

Y en recomendación eso puede ser muy valioso, porque muchas veces el salto interesante no viene del vecino más parecido, sino del usuario que vive entre dos comunidades y que, precisamente por estar en esa posición, arrastra o anticipa combinaciones de preferencias menos obvias.

1.3 3. Objetivo formal de la metodología fusionada

El objetivo de la metodología no sería solamente predecir ratings con menor RMSE. Eso sería importante, sí, pero no suficiente para justificar la fusión.

Yo la formularía así:

> **Construir un modelo de recomendación basado en matrix factorization sobre una red social inferida, incorporando señales de frontera intercomunitaria en redes con comunidades superpuestas, de modo que el espacio latente del usuario refleje no solo proximidad estructural sino también capacidad de conexión entre grupos.**

Dicho más sencillo: el usuario no queda descrito únicamente por cuánto se parece a otros, sino también por **qué papel juega entre comunidades**.

1.4 4. Estructura general del pipeline

La metodología completa la dividiría en siete fases. No porque haya que burocratizarla, sino porque conviene que se vea muy claro dónde termina una idea y dónde empieza la otra.

Fase 1. Preparación de datos y construcción de cascadas

En esta fase se parte del conjunto usuario–ítem–tiempo. Si seguimos la lógica de ws-dmaa, el caso natural es MovieLens: 100,004 ratings, 671 usuarios y 9,066 películas. Cada película se interpreta como una cascada; es decir, para una película m_c, se toma el conjunto de pares (u_i, t_i) que indican qué usuario calificó esa película y en qué instante. Así se obtiene un total de 9,066 cascadas, una por película.

Aquí conviene dejar claro algo: no estamos suponiendo que un usuario "infecta" literalmente a otro para que vea una película. Lo que estamos haciendo es adoptar la lógica de inferencia de difusión como una forma de reconstruir una red latente de influencia o cercanía conductual. Esa es justamente la gracia del enfoque de ws-dmaa: usar el aparato de NETINF para pasar de una secuencia temporal de interacciones a una estructura relacional entre usuarios.

Producto de la fase 1

Un conjunto de cascadas temporales listas para el proceso de inferencia de red.

Fase 2. Inferencia de la red usuario–usuario

En esta fase se corre **NETINF** sobre las cascadas generadas en la fase anterior. ws-dmaa contempla tres modelos paramétricos de transmisión: exponencial, power-law y Rayleigh, siguiendo la formulación clásica del problema de inferencia de redes a partir de cascadas. El problema que se optimiza es, en esencia, encontrar un grafo oculto que maximice la probabilidad de observar el conjunto de cascadas bajo el modelo de transmisión adoptado.

Mi recomendación práctica sería empezar por el modelo **exponencial**, no por capricho, sino porque en ws-dmaa fue el que dio mejor comportamiento empírico: RMSE promedio 0.7867, MAE 0.6833 y R^2 de 0.2959, superando no solo al filtrado colaborativo base, sino también a los otros dos modelos de transmisión evaluados.

Ahora bien, para la fusión con Appl. Sci. aquí aparece una decisión metodológica importante. NETINF infiere originalmente una red **dirigida**, porque la lógica de difusión es

direccional. En cambio, el artículo de Appl. Sci. formula $\tilde{h}_v$ sobre redes **no dirigidas y no ponderadas**, y además deja explícitamente como trabajo futuro la extensión a redes dirigidas y ponderadas. Por eso, para una primera versión limpia y defendible de la fusión, yo propondría una simplificación controlada: convertir la red inferida a una versión no dirigida, por ejemplo mediante simetrización, y trabajar primero en ese espacio.

No porque sea la única opción, sino porque es la manera más sólida de no mezclar supuestos incompatibles demasiado pronto.

Producto de la fase 2

Una red usuario–usuario inferida, preferiblemente en una versión no dirigida depurada para el análisis comunitario posterior.

Fase 3. Detección de comunidades superpuestas

Aquí empieza de verdad la fusión con Appl. Sci.

Sobre la red inferida se ejecuta un algoritmo de **detección de comunidades con traslape**. Este punto no es decorativo. En Appl. Sci. se deja bastante claro que la utilidad de $\tilde{h}_v$ depende de la calidad de las comunidades subyacentes. Si las comunidades son pobres, artificiales o demasiado forzadas, la interpretación del score se debilita. El artículo recomienda explícitamente usar métodos robustos al traslape cuando las comunidades no están dadas de antemano.

En esta fase yo sería muy explícito con el lector: aquí no quiero comunidades "bonitas" para visualización; quiero comunidades que representen grupos conductualmente o semánticamente coherentes. En nuestro contexto, eso significa que las comunidades deben reflejar patrones relacionales plausibles entre usuarios derivados del comportamiento de rating.

Recomendación práctica

No casarme de entrada con un solo algoritmo. Lo razonable es probar dos o tres detectores overlap-aware y evaluar estabilidad. No hace falta que eso explote en complejidad desde el primer borrador, pero sí conviene no fingir que la comunidad detectada es una verdad revelada.

Producto de la fase 3

Para cada usuario v, un conjunto de membresías $C(v)$, es decir, las comunidades superpuestas a las que pertenece.

Fase 4. Cálculo de atributos de frontera con $\tilde{h}_v$

Una vez se tienen las membresías comunitarias, se calcula la métrica de **local pluralistic homophily**.

La idea, resumida sin perder rigor, es esta. Para cada nodo v, se evalúa cuánta parte de su identidad comunitaria aparece representada en su vecindario inmediato. Eso se resume en una cantidad $s(v)$. Luego se mide la discrepancia local δ_v, comparando $s(v)$ con los valores de sus vecinos. Finalmente, se normaliza respecto a un referente global para obtener $\tilde{h}_v = \lambda - \delta_v$. Los valores más negativos corresponden a nodos cuya membresía está más desalineada con la de sus vecinos, es decir, candidatos naturales a **boundary-spanners**.

Lo bonito de esta parte es que no estamos importando una centralidad más. Estamos importando una señal de otra naturaleza. El propio artículo muestra que $\tilde{h}_v$ tiende a divergir de baselines topológicos y que detecta poblaciones funcionalmente distintas de nodos. Dicho de forma menos fría: esta métrica no va detrás del hub típico, sino del usuario que hace de interfaz entre comunidades.

Atributos que yo derivaría aquí

No me quedaría solo con $\tilde{h}_v$. También extraería:

- $m(v) = |C(v)|$, número de membresías por usuario;
- $s(v)$, alineación comunitaria local;

- δ_v, disimilitud vecinal local;
- quizá un indicador binario o cuantílico de "usuario frontera" basado en percentiles bajos de $\tilde{h}_v$.

No porque todo haya que meterlo al modelo final, sino porque es mejor tener la batería completa y luego hacer ablación.

Producto de la fase 4

Un vector de atributos comunitarios y de frontera para cada usuario.

Fase 5. Integración con la capa de atributos de usuario del CMF

Aquí la fusión se vuelve completamente operativa.

ws-dmaa usa un esquema de **Collective Matrix Factorization** en el que, además de aproximar la matriz de ratings R, se aproxima una matriz de atributos de usuario A. Ese es exactamente el punto por donde conviene entrar. No hay que romper el modelo ni inventar una arquitectura exótica: basta con **extender la matriz A**.

En el artículo original, A ya incluye propiedades de red como degree, betweenness, closeness, eigenvector, farness, community structure, eccentricity y hubs/authorities. Lo que propongo es que ahora esa matriz se amplíe con los atributos provenientes del análisis de comunidades superpuestas: $\tilde{h}_v$, $m(v)$, $s(v)$, δ_v, y cualquier descriptor complementario que resulte estable.

En términos prácticos, el vector de atributos del usuario u quedaría más o menos así:

$$a_u = [\text{degree}, \text{betweenness}, \text{closeness}, \text{eigenvector}, \text{farness}, \text{eccentricity}, \text{hub/authority}, \text{community structure}, \tilde{h}_u,$$

La interpretación aquí me parece muy potente: el factor latente del usuario deja de depender solo de lo que califica y de lo "central" que es, y pasa a depender también de **si está incrustado dentro de una comunidad o si se mueve entre varias**.

Producto de la fase 5

Una matriz de atributos enriquecida, lista para alimentar el modelo CMF.

Fase 6. Variante fuerte: regularización social guiada por frontera

Hasta aquí ya habría una fusión válida y publicable. Pero si quisiera empujarla un poco más, haría una segunda versión, más ambiciosa.

En vez de usar $\tilde{h}_v$ solo como feature, lo incorporaría también en la **regularización social del espacio latente**.

La idea sería la siguiente: si dos usuarios están conectados en la red inferida, no siempre conviene forzar del mismo modo la cercanía de sus vectores latentes. Si ambos son usuarios muy intra-comunidad, una regularización fuerte puede tener sentido. Pero si alguno es un usuario frontera con $\tilde{h}_v$ muy negativo, quizá no conviene suavizarlo demasiado, porque justamente su valor está en mezclar señales de distintos grupos.

Entonces se puede introducir un término de regularización del estilo

$$\sum_{(u,v)\in E} w_{uv} \|p_u - p_v\|^2,$$

donde el peso w_{uv} ya no depende solo de la existencia del enlace, sino de la relación comunitaria entre u y v y de sus valores de frontera. Esta es una extensión propuesta, no algo que esté implementado tal cual en alguno de los dos papers, pero me parece la prolongación más natural y más interesante de la fusión. La ventaja es que la información de frontera deja de ser solo descriptiva y pasa a modificar la geometría del espacio latente.

Producto de la fase 6

Un modelo CMF socialmente regularizado, sensible a interfaces intercomunitarias.

Fase 7. Evaluación experimental y lógica de comparación

Aquí yo sería muy disciplinado. No mezclaría todo de una vez. Haría una escalera de comparación.

Modelo 1

MF o collaborative filtering base.

Modelo 2

ws-dmaa original: red inferida + propiedades topológicas clásicas en CMF.

Modelo 3

ws-dmaa + atributos de frontera: $\tilde{h}_v$, $m(v)$, $s(v)$, δ_v.

Modelo 4

ws-dmaa + atributos de frontera + regularización social adaptativa.

La evaluación básica debe mantener RMSE, MAE y R^2, porque eso permite compararse con el artículo base y no perder continuidad metodológica. ws-dmaa reporta justamente esas métricas y muestra mejora clara frente al baseline.

Pero si queremos justificar por qué la capa de frontera aporta algo más que "otro feature", entonces conviene añadir también métricas complementarias de recomendación, por ejemplo cobertura, diversidad o alguna noción de exposición intercomunitaria. Ahí yo hablaríade algo como *cross-community exposure* o *boundary-spanning exposure*, que conecta mejor con la lógica estructural de Appl. Sci.

1.5 5. Qué hipótesis de trabajo sostienen la fusión

Yo dejaría las hipótesis escritas con bastante claridad.

Hipótesis 1

La red inferida desde cascadas de rating contiene señal relacional útil para recomendación, más allá de la matriz usuario–ítem por sí sola. Eso está en la base de ws-dmaa.

Hipótesis 2

Dentro de esa red inferida, los usuarios ubicados en interfaces entre comunidades superpuestas cumplen un papel distinto al de los hubs o nodos densamente embebidos. Esa es justamente la tesis de Appl. Sci.

Hipótesis 3

Incorporar atributos de frontera al CMF permite modelar mejor usuarios híbridos, transicionales o estructuralmente expuestos a múltiples grupos, lo que debería traducirse en mejoras de predicción y, sobre todo, en una recomendación menos miope.

Hipótesis 4

Una regularización latente guiada por estructura de frontera puede preservar mejor la riqueza intercomunitaria del sistema que una regularización social uniforme.

1.6 6. Qué problemas resuelve realmente esta fusión

Aquí conviene ser honesto. Esta metodología no resuelve mágicamente todo. Pero sí ataca de frente tres problemas reales.

Primero, **sparsity**. ws-dmaa ya muestra que usar propiedades de una red inferida mejora el desempeño frente a baselines más simples, especialmente cuando la matriz usuario–ítem es dispersa.

Segundo, **usuarios híbridos**. Hay usuarios cuyas preferencias no encajan limpiamente en una sola comunidad. El enfoque clásico tiende a promediarlos mal o a empujarlos hacia el centro de una sola región del espacio latente. La señal de frontera ayuda a reconocer que ese usuario no está mal definido: está, más bien, **mal modelado** si no se contempla su papel intercomunitario.

Tercero, **exposición entre grupos**. Si más adelante quieres hablar de recomendaciones que crucen comunidades sin perder relevancia, esta fusión te deja una base matemática y estructural mucho más sólida que un discurso genérico sobre diversidad.

1.7 7. Limitaciones que yo dejaría declaradas desde el inicio

Aquí no me escondería.

La primera limitación es que $\tilde{h}_v$ depende de la calidad de las comunidades detectadas. Si las comunidades son malas, el score pierde fuerza interpretativa. El propio artículo lo dice claramente.

La segunda es que estamos combinando una red inferida desde un proceso originalmente dirigido con una métrica formulada para redes no dirigidas y no ponderadas. Para una primera fase experimental esto se puede resolver con simetrización, pero si el trabajo crece, una extensión de $\tilde{h}_v$ a redes dirigidas/pesadas sería una contribución interesante por sí misma. Appl. Sci. incluso la menciona como trabajo futuro.

La tercera es que no todo usuario frontera será automáticamente útil para recomendación. El hecho de estar en la interfaz entre comunidades no garantiza por sí solo capacidad predictiva. Por eso la evaluación tiene que hacerse con ablaciones y no con intuiciones bonitas.

1.8 8. Cómo resumiría la metodología en una sola idea

Si tuviera que decirlo de forma breve, pero bien dicha, lo pondría así:

> **La metodología fusiona un recomendador basado en matrix factorization sobre una red social inferida con una capa de análisis de fronteras comunitarias superpuestas, de modo que los atributos del usuario no describan solo centralidad o proximidad, sino también desalineación estructural e interfaz entre grupos.**

O, mas resumido si se quiere:

> **La idea es no quedarnos únicamente con quién se parece a quién, sino meter en el modelo quién está entre quiénes.**

Y creo que esa frase captura muy bien el espíritu de la fusión.

1.9 9. Cierre operativo: cuál sería mi ruta de implementación

Si yo tuviera que convertir esto en plan de trabajo concreto, haría lo siguiente:

Primero, replicar ws-dmaa tal como está: cascadas, NETINF, atributos clásicos, CMF. Eso me da línea base interna y me obliga a entender bien el pipeline original.

Luego, sobre la red inferida, detectar comunidades superpuestas y calcular $\tilde{h}_v$ y sus variables auxiliares. Esa sería la primera inyección real de Appl. Sci.

Después, añadir esas señales a la matriz de atributos del usuario y repetir la evaluación. Si ahí ya aparece mejora, la fusión mínima queda justificada.

Y solo después de eso, metería la versión más fuerte: regularización social adaptativa guiada por frontera.

Ese orden importa mucho. Porque si se quiere hacer todo al tiempo, lo más probable es que después no se sepa qué fue lo que realmente aportó.